escuela
británica de
artes creativas
y tecnología

Título de la tarea: Tarea M18.

Nombre del estudiante: Eliuth Misraim Rojas Villavicencio.

Tema: Agile Data Science y Minería de Datos con Orange II.

Institución educativa: Escuela Británica de Artes Creativas y Tecnología.

Objetivo: revisar un caso aplicativo sobre metodología de Ciencia de Datos, de manera que pueda relacionarlo con mi área laboral. Asimismo, aplicar los conceptos avanzados de manejo de datos en Orange.

1. Explique las diferencias de trabajar un proyecto de manera tradicional vs realizarlo de manera ágil.

Metodología Tradicional (Waterfall)

La metodología tradicional, también conocida como Waterfall, sigue un enfoque secuencial y lineal. Cada fase del proyecto debe completarse antes de pasar a la siguiente. Las fases típicas incluyen:

1. **Requisitos:** Recopilación y documentación de todos los requisitos del proyecto.
2. **Diseño:** Creación de un diseño detallado del sistema.
3. **Implementación:** Desarrollo del sistema basado en el diseño.
4. **Pruebas:** Verificación y validación del sistema.
5. **Despliegue:** Implementación del sistema en el entorno de producción.
6. **Mantenimiento:** Resolución de problemas y mejoras continuas.

Metodología Ágil

La metodología ágil es iterativa e incremental. Los proyectos se dividen en pequeñas partes llamadas "sprints" (generalmente de 2 a 4 semanas), y cada sprint produce una versión funcional del producto. Las fases típicas incluyen:

1. **Planificación del Sprint:** Definición de los objetivos y tareas del sprint.
2. **Desarrollo:** Implementación de las funcionalidades definidas.
3. **Revisión del Sprint:** Presentación del trabajo completado y recopilación de feedback.
4. **Retrospectiva:** Evaluación del sprint para identificar mejoras.

1.1 Ejemplifique mediante un caso real de un proyecto de Ciencia de Datos.

Ejemplo: Proyecto de Ciencia de Datos en el Almacén de Fastenal

Metodología Tradicional

1. **Requisitos:** Definir todos los requisitos del proyecto, como la necesidad de un sistema de optimización de inventarios.
2. **Diseño:** Crear un diseño detallado del sistema de optimización, incluyendo la arquitectura de datos, algoritmos a utilizar, y la infraestructura necesaria.
3. **Implementación:** Desarrollar el sistema de optimización completo basado en el diseño.
4. **Pruebas:** Realizar pruebas exhaustivas para asegurar que el sistema funcione correctamente.
5. **Despliegue:** Implementar el sistema de optimización en el entorno de producción.
6. **Mantenimiento:** Resolver problemas y realizar mejora continua basada en el feedback de los usuarios.

Metodología Ágil

1. **Planificación del Sprint:** Definir los objetivos del primer sprint, como la creación de un prototipo básico del sistema de optimización de inventarios.
2. **Desarrollo:** Implementar las funcionalidades definidas para el primer sprint.
3. **Revisión del Sprint:** Presentar el prototipo a los stakeholders y recopilar feedback.
4. **Retrospectiva:** Evaluar el sprint para identificar mejoras.
5. **Iteración:** Repetir el proceso para el siguiente sprint, incorporando el feedback y mejorando el sistema de optimización de manera incremental.

1.2 ¿Qué ventajas presenta el trabajar de la segunda manera?

Ventajas de la Metodología Ágil

1. **Flexibilidad:** Permite adaptarse a cambios en los requisitos y prioridades del proyecto.
2. **Feedback Continuo:** Facilita la recopilación de feedback de los stakeholders y usuarios, lo que mejora la calidad del producto.
3. **Entrega Rápida:** Proporciona versiones funcionales del producto en intervalos cortos, lo que permite una entrega más rápida de valor.
4. **Mejora Continua:** Promueve la mejora continua a través de retrospectivas y ajustes en cada sprint.

1.3¿Cuáles serían las desventajas potenciales que podría tener?

Desventajas Potenciales de la Metodología Ágil

1. **Falta de Documentación:** Puede haber menos documentación detallada, lo que puede ser un problema para el mantenimiento a largo plazo.
2. **Dependencia del Equipo:** Requiere un equipo altamente colaborativo y autoorganizado.
3. **Alcance Incierto:** El alcance del proyecto puede cambiar con frecuencia, lo que puede dificultar la planificación a largo plazo.
4. **Reuniones Frecuentes:** Las reuniones diarias y las revisiones de sprint pueden consumir tiempo significativo.

2. **Imagina que eres un investigador médico que recopila datos para un estudio. Has recopilado datos sobre un conjunto de pacientes, todos ellos con la misma enfermedad. Durante su tratamiento, cada paciente ha respondido a uno de los 5 medicamentos, el fármaco A, el fármaco B, el fármaco C (de proveedor nacional), el fármaco X y el Y (de proveedor extranjero).**
3. **Tu trabajo consistirá en construir un modelo mediante Orange que permita averiguar cuál medicamento podría ser apropiado para un futuro paciente con la misma enfermedad.**
4. **Elabore un reporte detallado (a manera de proyecto final del módulo) que muestre los hallazgos obtenidos con la finalidad de encontrar el modelo que hace la mejor predicción de todos los que se encuentran disponibles en Orange.**

Reporte Detallado de Evaluación de Modelos

Introducción

En este reporte se presentan los hallazgos obtenidos de la evaluación y calibración de diferentes modelos de clasificación utilizando Orange. El objetivo es determinar cuál de los modelos disponibles hace la mejor predicción para un conjunto de datos de pacientes tratados con diferentes medicamentos. Los modelos evaluados son Logistic Regression, Random Forest, SVM, Tree, kNN, AdaBoost, Gradient Boosting, y Neural Network. Las métricas de evaluación utilizadas son AUC, CA, F1, Prec, Recall, y MCC.

He agregado un cuadro de descripción del significado de cada abreviatura sobre los métricos de evaluación. Aquí está el resumen de las abreviaturas:

Abreviatura	Significado
AUC	Area Under the Curve
CA	Classification Accuracy
F1	F1 Score
Precisión	Precision
Recall	Recall
MCC	Matthews Correlation Coefficient

Ilustración 1 Resumen de Abreviaturas para evaluación de modelos.

Evaluación de Modelos

Modelo	AUC	CA	F1	Precisión	Recall	MCC
AdaBoost	0.888	0.850	0.835	0.838	0.850	0.752
Gradient Boosting	0.894	0.843	0.825	0.835	0.843	0.736
kNN	0.861	0.729	0.714	0.703	0.729	0.543
Logistic Regression	0.936	0.871	0.854	0.873	0.871	0.789
Neural Network	0.940	0.819	0.809	0.798	0.843	0.772
Random Forest	0.940	0.864	0.832	0.860	0.864	0.772
SVM	0.936	0.871	0.854	0.873	0.871	0.789
Tree	0.883	0.821	0.822	0.804	0.821	0.722

Ilustración 2 Tabla de evaluación de modelos de Orange.

Descripción del comportamiento de los modelos:

1. **AdaBoost**: Tiene un buen rendimiento general con una AUC de 0.888 y una precisión de 0.838. Su MCC es de 0.752, lo que indica una buena correlación.
2. **Gradient Boosting**: Similar a AdaBoost, pero con una AUC ligeramente mejor de 0.894. Su MCC es de 0.736.
3. **kNN**: Tiene el peor rendimiento en todas las métricas con una AUC de 0.861 y una precisión de 0.703. Su MCC es de 0.543, lo que indica una baja correlación.
4. **Logistic Regression**: Uno de los mejores modelos con una AUC de 0.936 y una precisión de 0.873. Su MCC es de 0.789, lo que indica una alta correlación.
5. **Neural Network**: Tiene la mejor AUC de 0.940, pero su precisión es menor en comparación con Logistic Regression. Su MCC es de 0.772.
6. **Random Forest**: Similar a Neural Network con una AUC de 0.940 y una precisión de 0.860. Su MCC es de 0.772.
7. **SVM**: Similar a Logistic Regression con una AUC de 0.936 y una precisión de 0.873. Su MCC es de 0.789.
8. **Tree**: Tiene un rendimiento aceptable con una AUC de 0.883 y una precisión de 0.804. Su MCC es de 0.722.

Análisis Comparativo

Métrica	Mejor Modelo	Mejor Puntuación	Peor Modelo	Peor Puntuación
AUC	Neural Network, Random Forest	0.940	kNN	0.861
CA	Logistic Regression, SVM	0.871	kNN	0.729
F1	Logistic Regression, SVM	0.854	kNN	0.714
Precisión	Logistic Regression, SVM	0.873	kNN	0.703
Recall	Logistic Regression, SVM	0.871	kNN	0.729
MCC	Logistic Regression, SVM	0.789	kNN	0.543

Ilustración 3 Tabla de análisis comparativo de modelos de Orange

Descripción del Análisis Comparativo:

Esta tabla proporciona un análisis comparativo de diferentes modelos basado en varias métricas: AUC (Area Under the Curve), CA (Classification Accuracy), F1 Score, Precisión, Recall y MCC (Matthews Correlation Coefficient). Para cada métrica, la tabla lista los mejores y peores modelos junto con sus respectivas puntuaciones.

- **AUC**: Mide la capacidad del modelo para distinguir entre clases. Valores más altos indican mejor rendimiento.
- **CA**: Representa la precisión general del modelo en clasificar instancias correctamente.
- **F1 Score**: Combina precisión y recall para proporcionar una única métrica de rendimiento del modelo.
- **Precisión**: Indica la proporción de identificaciones positivas que fueron realmente correctas.
- **Recall**: Mide la proporción de positivos reales que fueron correctamente identificados por el modelo.
- **MCC**: Proporciona una medida equilibrada del rendimiento del modelo, teniendo en cuenta verdaderos y falsos positivos y negativos.

Conclusión

Basado en las métricas de evaluación, el mejor modelo para el conjunto de datos de pacientes tratados con diferentes medicamentos es **Logistic Regression** o **SVM**.

Razones:

1. **Classification Accuracy (CA)**: Ambos modelos tienen la mejor precisión general con un valor de 0.871.
2. **F1 Score**: Ambos modelos tienen el mejor F1 Score con un valor de 0.854.
3. **Precision**: Ambos modelos tienen la mejor precisión con un valor de 0.873.
4. **Recall**: Ambos modelos tienen el mejor recall con un valor de 0.871.
5. **Matthews Correlation Coefficient (MCC)**: Ambos modelos tienen el mejor MCC con un valor de 0.789.

- Aunque los modelos **Neural Network** y **Random Forest** tienen el mejor AUC (0.940), su precisión y otras métricas no superan a **Logistic Regression** y **SVM**.
- Para este caso, **Logistic Regression** y **SVM** son los modelos más recomendados debido a su rendimiento superior en múltiples métricas clave.

5. Una vez establecido el modelo recomendado, úsalo para predecir los siguientes casos (interpretando verbalmente sus resultados):

Datos y predicciones

Logistic Regression	Random Forest	SVM	Tree	kNN	AdaBoost	Gradient Boosting	Age	Sex	bp	cholesterol	na_to_k
drugY	drugY	drugY	drugY	drugY	drugY	drugY	40	M	LOW	HIGH	24.222
drugY	drugY	drugY	drugY	drugB	drugY	drugY	55	F	HIGH	NORMAL	11.150

Ilustración 4 Tabla de Predicciones y casos de pacientes a predecir

Predicciones para los Pacientes

1. **Paciente 1:**
   - **Predicción de Medicamento:** Todos los modelos (Logistic Regression, Random Forest, SVM, Tree, kNN, AdaBoost, Gradient Boosting) predicen que se debe administrar **drugY**.
2. **Paciente 2:**
   - **Predicción de Medicamento:** La mayoría de los modelos (Logistic Regression, Random Forest, SVM, Tree, AdaBoost, Gradient Boosting) predicen que se debe administrar **drugY**. Sin embargo, el modelo kNN predice que se debe administrar **drugB**.

Conclusión

La mayoría de los modelos de clasificación predicen que se debe administrar **drugY**. Esto sugiere que **drugY** es el medicamento más adecuado para estos pacientes según los datos proporcionados y las predicciones de los modelos.

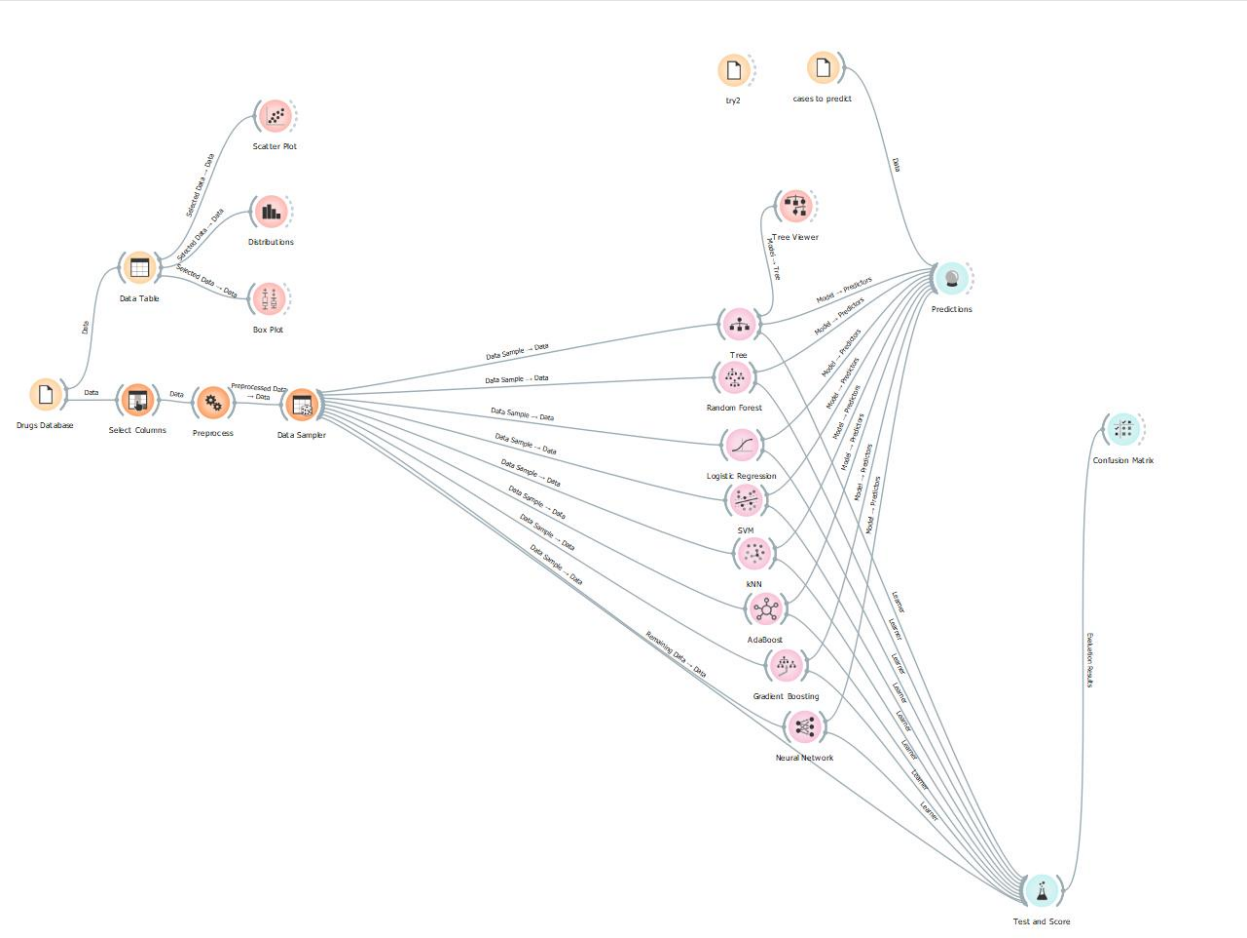

Ilustración 5 Array en Orange para la evaluación de modelos