escuela
británica de
artes creativas
y tecnología

Título de la tarea: Tarea M17.

Nombre del estudiante: Eliuth Misraim Rojas Villavicencio.

Tema: TDSP, BSPF y Minería de Datos con Orange I.

Institución educativa: Escuela Británica de Artes Creativas y Tecnología.

Objetivo: revisar un caso aplicativo sobre metodología de Ciencia de Datos, de manera que pueda relacionarlo con mi área laboral. Asimismo, tendrás oportunidad de aplicar los conceptos básicos de manejo de datos en Orange.

Caso de Estudio: Almacén de FASTENAL

1. **Lea el caso aplicativo "How To Use The 7 Step BSPF: A Customer Churn Example"**

2. **Explique con sus palabras de forma breve en qué consisten cada uno de los siete pasos planteados para crear un "Business Science Problem Framework (BSPF)" en este caso.**

   El Business Science Problem Framework (BSPF) es un proceso sistemático desarrollado para aplicar la ciencia de datos a problemas empresariales. Aquí están los siete pasos del BSPF explicados brevemente:

1. **Definición del Problema**: Primero, necesitas entender claramente cuál es el problema que quieres resolver en tu negocio. Esto implica saber qué objetivos tienes y qué resultados esperas obtener.
2. **Recolección de Datos:** Luego, debes reunir toda la información relevante que te ayudará a resolver el problema. Esto puede incluir datos de tu empresa, información de tus clientes, datos del mercado, entre otros.
3. **Preparación de Datos:** Una vez que tienes los datos, necesitas limpiarlos y organizarlos para que sean útiles. Esto puede significar eliminar datos incorrectos, normalizar la información y crear nuevas variables que te ayuden en el análisis.
4. **Análisis Exploratorio de Datos (EDA):** Aquí, haces un análisis inicial de los datos para entender sus características principales. Buscas patrones, tendencias y cualquier anomalía que pueda existir.
5. **Modelado:** En este paso, aplicas técnicas estadísticas y de aprendizaje automático para crear modelos que te ayuden a predecir o explicar el problema que estás tratando de resolver.

6. Evaluación del Modelo: Después de crear los modelos, necesitas evaluar su precisión y eficacia. Utilizas métricas adecuadas para ver qué tan bien están funcionando y haces ajustes si es necesario.
7. Implementación y Monitoreo: Finalmente, implementas el modelo en tu negocio y monitoreas su desempeño. Asegúrate de que el modelo esté generando los resultados esperados y haz ajustes si es necesario.

3. Comente si es aplicable a su entorno laboral y por qué.

Aplicabilidad en un almacén de Fastenal

Este marco de trabajo es muy aplicable en un almacén de Fastenal porque:

1. **Definición del Problema:** Puedes identificar problemas como la optimización del inventario, mejorar la eficiencia operativa, y reducir costos.
2. **Recolección de Datos:** Fastenal puede recopilar datos sobre inventario, ventas, tiempos de entrega, y costos operativos.
3. **Preparación de Datos:** Los datos del almacén pueden necesitar limpieza y organización para eliminar inconsistencias y prepararlos para el análisis.
4. **Análisis Exploratorio de Datos:** Analizar los datos del almacén puede revelar patrones en las ventas, identificar productos de alta demanda, y detectar ineficiencias operativas.
5. **Modelado:** Modelos predictivos pueden ayudar a anticipar la demanda de productos, optimizar el inventario, y mejorar la planificación logística.
6. **Evaluación del Modelo:** Evaluar los modelos para asegurar que las predicciones sean precisas y útiles para la toma de decisiones.
7. **Implementación y Monitoreo:** Implementar los modelos en las operaciones del almacén y monitorear su desempeño para asegurar que están generando los beneficios esperados.

4. **Considere la base de datos de muestra “heart_disease.tab“ disponible en Orange.**
5. **Elabore 3 tipos de gráficos distintos a los vistos en este módulo (disponibles en la sección “Visualize”) aplicando diversas condiciones y comentando sobre el uso práctico que podría darles.**

1. **Distribución de Frecuencia de “Chest Pain” (Dolor de Pecho)**

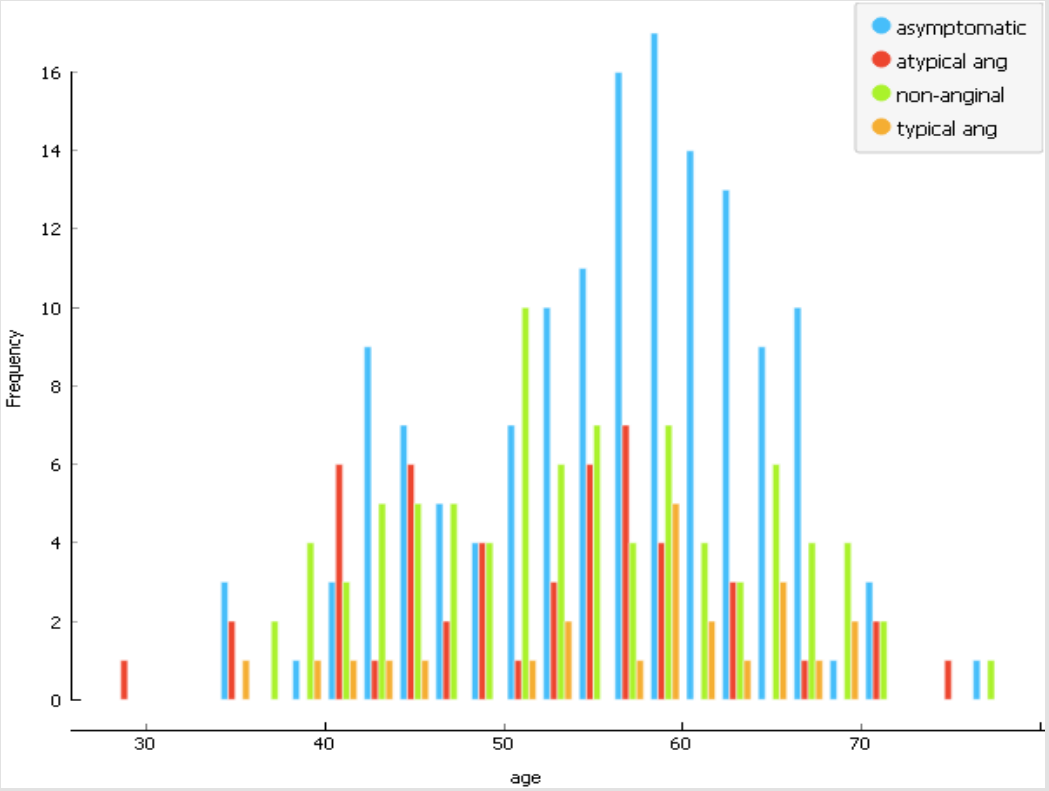

Descripción detallada:

- **Eje horizontal:** Representa la edad, con un rango que va desde los 30 hasta los 80 años.
- **Eje vertical:** Representa la frecuencia, con un rango que va desde 0 hasta 16.
- **Categorías de dolor en el pecho:**
    - Azul: 'asymptomatic' (asintomático)
    - Rojo: 'atypical ang' (angina atípica)
    - Verde: 'non-anginal' (no anginal)
    - Amarillo: 'typical ang' (angina típica)

Comentario sobre las distribuciones por edad:

- Asymptomatic (asintomático): Es la categoría más frecuente, especialmente entre las edades de aproximadamente 40 a 70 años, alcanzando su pico máximo alrededor de los 55 años. La frecuencia del dolor en el pecho asintomático disminuye significativamente antes y después del rango mencionado.
- Atypical ang (angina atípica), non-anginal (no anginal) y typical ang (angina típica): Estas tres categorías tienen frecuencias mucho menores comparadas con la categoría asintomática. La distribución de estas categorías es más dispersa y no muestra picos tan pronunciados como la categoría asintomática. Sin embargo, también tienden a concentrarse entre las edades de aproximadamente 40 a 70 años.

En resumen, la mayoría de los casos de dolor en el pecho reportados en la base de datos son asintomáticos, con una clara concentración en personas de mediana edad. Las otras categorías de dolor en el pecho son menos frecuentes y están más dispersas a lo largo de las edades.

2. **Diagrama de dispersión con relación entre edad y concentración de colesterol, (con división por género y el color basado en la concentración de colesterol.)**

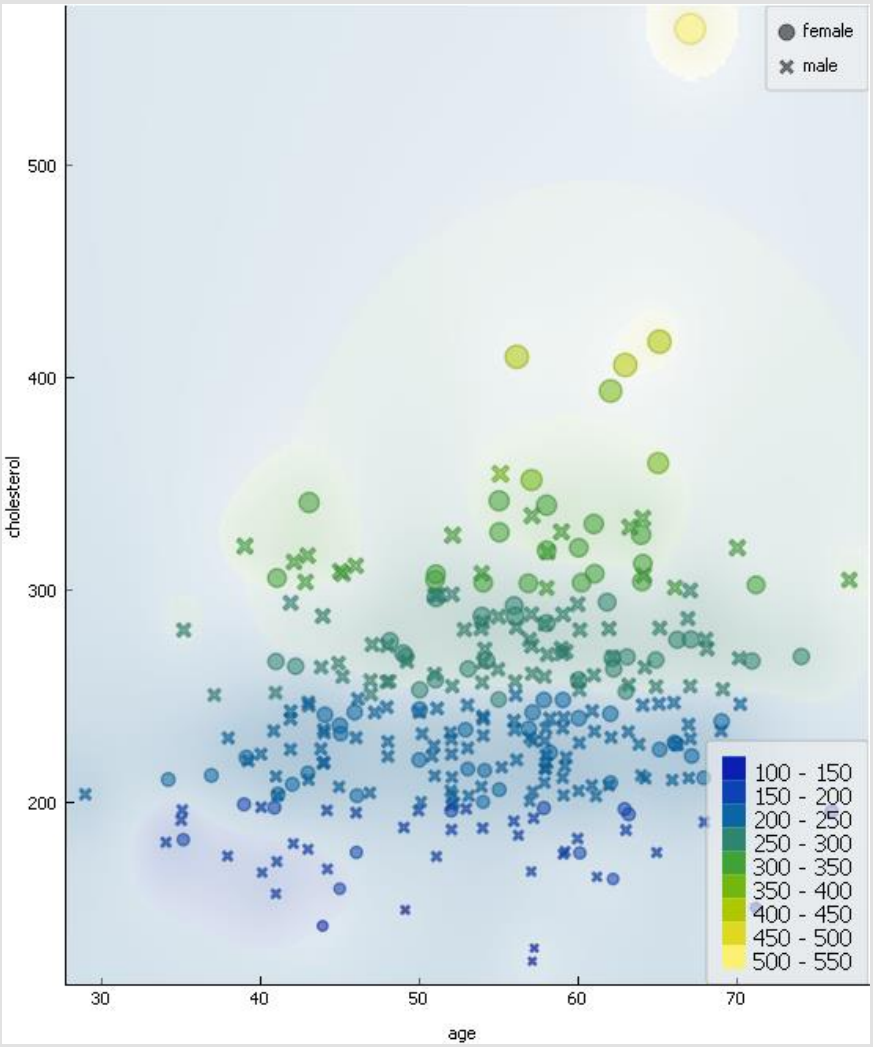

Descripción detallada:

- **Eje horizontal (x)**: Representa la edad, que varía aproximadamente entre 30 y 80 años.
- **Eje vertical (y)**: Representa la concentración de colesterol, que varía aproximadamente entre 100 y 550 mg/dL.

- **Codificación por color**: Los puntos están codificados por color según un gradiente que va del azul al amarillo, indicando concentraciones crecientes de colesterol. La leyenda a la derecha del gráfico especifica los rangos de colores:
    - Azul oscuro: 100 - 150 mg/dL
    - Azul claro: 150 - 200 mg/dL
    - Verde claro: 200 - 250 mg/dL
    - Verde medio: 250 - 300 mg/dL
    - Verde oscuro: 300 - 350 mg/dL
    - Amarillo claro: >350 mg/dL
- **División por género**:
    - **Círculos**: Representan a las mujeres.
    - **Cruces**: Representan a los hombres.

Comentario sobre la relación entre edad y concentración de colesterol:

1. **Distribución general**: La mayoría de los puntos se concentran en rangos más bajos de colesterol (azul oscuro a verde medio), especialmente para edades menores.
2. **Tendencia con la edad**: A medida que aumenta la edad, parece haber una tendencia hacia concentraciones más altas de colesterol (verde oscuro a amarillo).
3. **Diferencias por género**:
    - Para las mujeres (círculos), hay una mayor dispersión en las concentraciones más altas (>350 mg/dL) comparado con los hombres.
    - Para los hombres (cruces), aunque también hay puntos en concentraciones altas, parecen estar más distribuidos uniformemente sin tanta aglomeración en valores extremos altos.

En resumen, existe una tendencia general al aumento del colesterol con la edad para ambos géneros, pero esta tendencia parece ser más pronunciada o variable para las mujeres en concentraciones muy altas.

3. Diagrama de violín: distribución de la edad para tres categorías de talasemia.

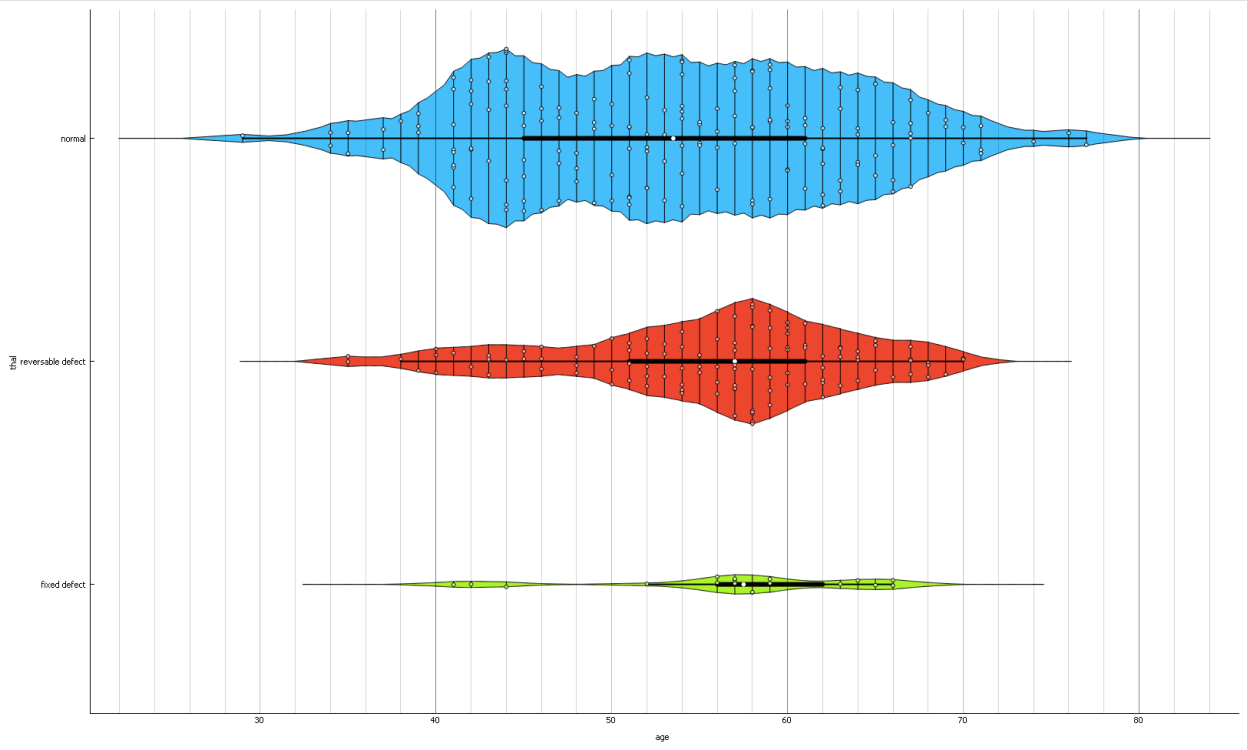

Descripción detallada:

Normal: Representado por un violín azul. La distribución es más amplia y uniforme, indicando una mayor variabilidad en las edades dentro de esta categoría.

Reversible Defect: Representado por un violín rojo. La distribución es más concentrada alrededor de ciertas edades, mostrando menos variabilidad comparado con la categoría normal.

Fixed Defect: Representado por un violín verde. Este tiene la menor variabilidad y se concentra principalmente en un rango estrecho de edades.

Relación entre los tipos de talasemia y las distribuciones de edad:

Normal: Las personas con talasemia clasificada como 'normal' tienen una amplia gama de edades, lo que indica una distribución más uniforme y variada. Esto puede incluir individuos con talasemia menor, que generalmente presentan síntomas leves o ninguno.

Reversible Defect: Las personas con talasemia clasificada como 'reversible defect' tienden a estar concentradas en ciertas edades específicas, mostrando una distribución menos uniforme. Este tipo puede corresponder a talasemia intermedia, donde los síntomas son más pronunciados y pueden requerir tratamiento ocasional.

Fixed Defect: Las personas con talasemia clasificada como 'fixed defect' están principalmente dentro de un rango muy estrecho de edades, indicando una concentración significativa en edades específicas. Este tipo puede corresponder a talasemia mayor, que es la forma más grave y requiere tratamiento continuo, como transfusiones de sangre regulares.

En resumen, la distribución de edades en las diferentes categorías de talasemia sugiere que las formas más graves de la enfermedad (como 'fixed defect') están más concentradas en rangos de edad específicos, posiblemente debido a la necesidad de tratamiento continuo y la gravedad de los síntomas. Las formas menos graves (como 'normal') muestran una mayor variabilidad en las edades, reflejando una menor necesidad de intervención médica constante.
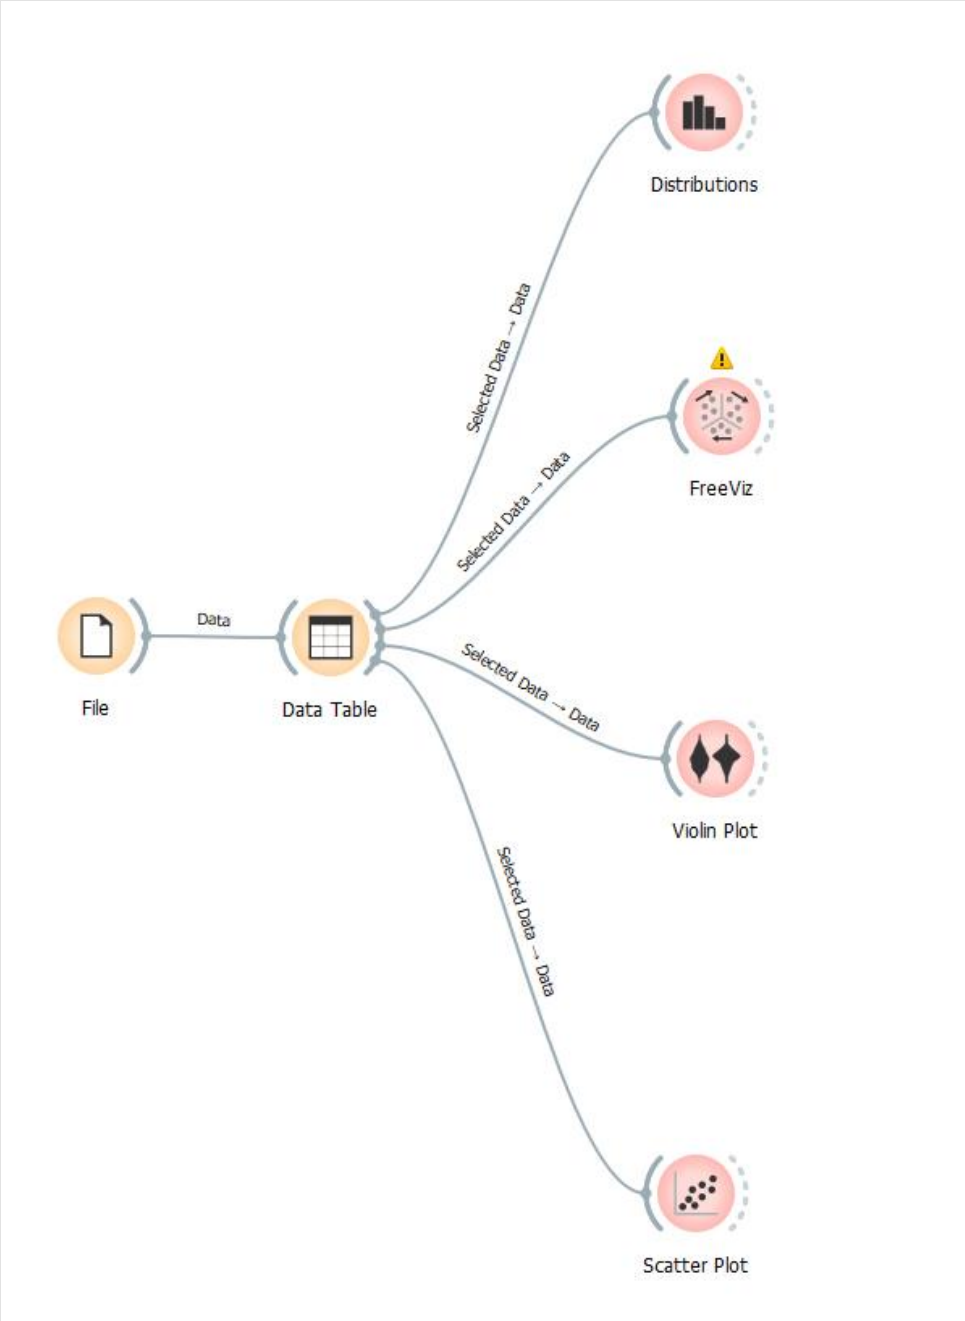
Orange array