

Regresión Logística & Modelado de Probabilidades

Cómo convertir una combinación lineal de variables en una probabilidad, cómo se entrena por máxima verosimilitud, y cómo evaluar y desplegar el clasificador con un pipeline reproducible.

DATASET

drugs.csv · 200 pacientes

LIBRERÍA

scikit-learn

CASO DE USO

Proveedor Nacional vs. Extranjero

— MAPA DEL CUADERNO

Siete bloques, una idea central

01-02 · FUNDAMENTOS

Conceptos clave: sigmoide, odds y máxima verosimilitud.

03 · DIAGNÓSTICO

Matriz de confusión, curva ROC y métrica AUC.

04 · PROYECTO

Caso práctico: clasificar el origen de un fármaco.

05 · SOLVERS

lbfgs, newton-cg, sag, saga — ¿importa cuál uso?

06 · NIVEL PRO



Pipeline + clase OOP estructurada para producción.

07 · CIERRE

Glosario, errores comunes y autoevaluación.

Una recta no sabe **dónde detenerse**

Una regresión lineal predice valores entre $-\infty$ y $+\infty$. Pero una probabilidad nunca puede ser menor a 0 ni mayor a 1. Necesitamos una función que **comprima** cualquier número real dentro de ese rango.



La función **Sigmoide**

$$S(z) = 1 / (1 + e^{-z})$$

- ▶ Actúa como un **embudo**: cualquier valor de Z real cae siempre en $(0, 1)$.
- ▶ $S(0) = 0.5 \rightarrow$ el umbral estándar corresponde exactamente a $Z = 0$.
- ▶ Simetría perfecta: $S(-z) = 1 - S(z)$.

De la probabilidad al **log-odds**

Si despejamos z de la sigmoide obtenemos el **logit**: el modelo es lineal en el log-odds, no en la probabilidad pura.

logit: el modelo SÍ es lineal aquí $\ln(p / (1-p)) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$

Odds = $p / (1-p)$

$p = 0.8 \rightarrow \text{odds} = 4$
(4 a 1 a favor)

$\beta > 0$

$e^{\beta} > 1 \rightarrow$ Sube la probabilidad de clase positiva.

$\beta < 0$

$e^{\beta} < 1 \rightarrow$ Baja la probabilidad de clase positiva.

Máxima Verosimilitud

Se buscan los coeficientes (β) que maximizan la probabilidad de haber observado las etiquetas reales. No tiene solución cerrada como OLS: se resuelve con optimización numérica iterativa (descenso de gradiente, Newton-Raphson, etc.).

$$\ell(\beta) = \sum [y_i \ln(p_i) + (1-y_i) \ln(1-p_i)]$$

Matiz clave: scikit-learn no maximiza la verosimilitud pura; por defecto añade regularización L2 (parámetro C). **Por eso la escala de las variables sí importa.**

La Matriz de Confusión y ROC

	Predicho: POSITIVO	Predicho: NEGATIVO
Real: POSITIVO	VP (Verdadero Positivo)	FN (Falso Negativo)
Real: NEGATIVO	FP (Falso Positivo)	VN (Verdadero Negativo)

- **TPR / Sensibilidad** = $VP / (VP + FN)$
% de positivos reales atrapados.
- **FPR** = $FP / (FP + VN)$
% de falsas alarmas sobre negativos reales.

Curva ROC y AUC

- **AUC = 1.0** → Separación perfecta entre clases.
- **AUC = 0.5** → Equivale a lanzar una moneda al azar.
- El AUC mide qué tan bien *ordena* el modelo las predicciones, no si la probabilidad en sí misma está bien calibrada.

¿De dónde viene el fármaco?

Dataset de 200 pacientes con 5 variables clínicas. Reagrupamos 5 fármacos originales en 2 clases de negocio: proveedor **Nacional** vs. **Extranjero**.

145

EXTRANJERO (DRUGX, DRUGY)
· 72.5%

55

NACIONAL (DRUGA, B, C) · 27.5%

72.5%

LÍNEA BASE (PREDECIR SIEMPRE "EXTRANJERO")

Clases desbalanceadas: cualquier modelo útil debe superar claramente el 72.5% de accuracy de la línea base. Por eso evaluaremos con Precision, Recall y AUC.

La trampa del else silencioso

El dataset contiene errores tipográficos (mayúsculas/minúsculas). Un mapeo con **else** ocultará cualquier fármaco mal escrito clasificándolo incorrectamente sin avisar.

```
# ❌ FRÁGIL: Cualquier error tipográfico cae en "Extranjero"
def transformar(nombre):
    if nombre in ['drugA', 'drugB', 'drugC']:
        return 1
    else:
        return 0
```

```
# ✅ EXPLÍCITO: Falla intencionalmente si hay un valor nuevo
MAPA = {'drugA':1, 'drugB':1, 'drugC':1, 'drugX':0, 'drugY':0}
y = nombre.str.lower().map(MAPA)
assert y.isna().sum() == 0
```

El experimento que cambia todo

Comparamos 3 formas de codificar la variable "Presión Sanguínea" (BP) usando validación cruzada:

Codificación	Lógica de Mapeo	Accuracy	AUC
A) Alfabético (LabelEncoder)	HIGH=0, LOW=1, NORMAL=2	0.955	0.988
B) Orden clínico real	LOW=0, NORMAL=1, HIGH=2	0.800	0.860
C) One-Hot Encoding	Una columna binaria por categoría	0.955	0.988

Conclusión: La relación de BP con el objetivo no es monótona (NORMAL nunca es Nacional, pero HIGH/LOW sí). Un modelo lineal no puede capturar esto con un solo coeficiente escalar. **One-Hot es siempre la opción más segura.**


Sin escalado no hay **convergencia**

Solver	Iteraciones Sin Escalar	Escalado (StandardScaler)
lbfgs	48 iter	9 iter
newton-cg	22 iter	5 iter
sag / saga	Falla (Warning)	22 - 31 iter

El umbral **0.5** no es ley

Umbral	Precision	Recall	Falsos Negativos
0.20	0.611	1.000	0
0.50	0.909	0.909	1
0.80	1.000	0.727	3

Un **Pipeline OOP**, no pasos sueltos



El preprocesamiento se ajusta **solo con datos de entrenamiento** para evitar fugas, y se aplica consistentemente a pacientes nuevos.

Errores **Comunes** a Evitar

- 1 **Usar LabelEncoder en variables predictoras:** Impone un orden numérico que el modelo asume como real.
- 2 **Ajustar (fit) el scaler antes de dividir:** Causa fuga de datos. Haz fit solo en train.
- 3 **Ignorar el ConvergenceWarning:** Significa que el solver no halló el óptimo. Escala las variables o sube max_iter.