

# Clustering jerárquico y PCA

Tema 26 · Cómo segmentar 100 clientes de Amazon sin etiquetas previas, y qué tan lejos confiar en el resultado.

100

clientes

9

variables

4

segmentos

36 %

varianza en 2D



# # Cómo agrupa el clustering aglomerativo

● ● ● ideas\_clave.py

**aglomerativo** # bottom-up

Cada cliente empieza solo; se une el par más parecido hasta quedar un solo grupo.

**distancia\_euclidiana**

Línea recta entre dos clientes en el espacio de 9 variables.

**ward** # criterio de enlace

Une los grupos cuya fusión sube menos la varianza interna.

● ● ● leer\_dendrograma.md


**eje X** clientes (las hojas)

**eje Y** altura de fusión: más alto = grupos más distintos

**corte** una línea horizontal cruza tantas ramas como clústeres quieras

**regla** busca un salto grande entre una fusión y la siguiente

# # Estandarizar antes de medir distancias



# experimento: agrupar con y sin StandardScaler


## ARI 0.14

Sin estandarizar salen segmentos casi sin relación con los correctos (1.0 = idénticos, 0 = azar). Durabilidad y Paquete dominan la distancia; Retorno casi no influye.

● ● ● formula.py

```
z = (x - media) / desv_est  
# cada variable: media 0, desv. 1
```

# # ¿Cuántos clústeres? $k = 4$ es una decisión



**silueta**  $\approx 0.11$  para cualquier  $k$ . Bajo 0.25 la estructura es débil: los grupos se traslapan.

El mayor salto está en  $k = 3$ . Elegimos  $k = 4$ : corte estable (altura 9.56), silueta igual a  $k = 3$ , grupos manejables (21, 24, 36 y 19 clientes) y perfiles interpretables.

# ningún  $k$  es óptimo matemático: combina métricas y utilidad de negocio.


## # Perfil de cada segmento

|                                        | Veloc. | Precio | Durab. | Imagen | V. educ. | Retorno | Paquete | Calidad | Estrellas |
|----------------------------------------|--------|--------|--------|--------|----------|---------|---------|---------|-----------|
| 0 · Educativos bien valorados (21)     | 0.24   | -0.18  | -0.39  | -0.48  | 0.70     | 0.32    | -0.03   | -0.54   | 0.81      |
| 1 · Paquetes grandes, precio alto (24) | -0.43  | 0.68   | -0.30  | 0.21   | -0.31    | 0.38    | 1.11    | -0.44   | 0.03      |
| 2 · Baja valoración general (36)       | -0.20  | -0.35  | -0.14  | -0.05  | -0.44    | -0.33   | -0.58   | -0.04   | -0.90     |
| 3 · Calidad y durabilidad (19)         | 0.66   | 0.00   | 1.08   | 0.37   | 0.46     | -0.21   | -0.27   | 1.23    | 0.76      |

Cian = por encima del promedio de todos los clientes; morado = por debajo. Las etiquetas son una lectura sugerida y los números de clúster son arbitrarios: pueden cambiar.

# # PCA: un lente 2D, no el análisis

Varianza acumulada por nº de componentes (%)



PC1 + PC2 explican **36.1 %**. El otro 63.9 % no aparece en el gráfico. Hacen falta 7 componentes para llegar al 80 %.

El clustering usa las **9 variables**; el PCA solo sirve para dibujar. Grupos encimados en 2D no prueban que estén mezclados en 9D.


● ● ● cargas.py

PC1 Estrellas .51 · Velocidad .49 · V. educativo .49

PC2 Paquete .52 · Precio .43 · Estrellas .43 · Durabilidad -.31

# el signo de un eje es arbitrario

# # Recomendar, con límites y repaso



Los afines se eligen por **distancia real** dentro del clúster, no por el orden del Excel. La base tiene evaluaciones, no compras: el siguiente paso es cruzar con el historial.

● ● ● repaso.py

?> ¿Por qué estandarizar?

La distancia la dominarían las variables de mayor escala; sin escalar, ARI 0.14.

?> ¿k = 4 es el óptimo?

No. El mayor salto está en  $k = 3$  y la silueta es plana: es una decisión.

?> ¿Cuánta información muestra el 2D?

36.1 % de la varianza: una vista parcial.

?> ¿Cómo se asigna un cliente nuevo?

No hay predict: se escala con el scaler ajustado y se toma el centroide más cercano.