

Clustering jerárquico y PCA

Del notebook a la explicación: qué hace cada paso, cómo leer cada gráfica y qué errores evitar.



100 clientes

9 variables

4 segmentos

36 % varianza en 2D

Mapa del notebook

Teoría en las diapositivas 3 y 4; después, un paso del notebook por diapositiva.

1

Ingesta y escala

diap. 5

2

Dendrograma

diap. 6

3

Elegir k

diap. 7

4

Asignar y perfilar

diap. 8

5

PCA

diap. 9 y 10

6

Recomendar

diap. 11

7

Clase Pro

diap. 12

8

Glosario y repaso

diap. 13 y 14

Clustering aglomerativo y Ward

● ● ● ideas_clave.py

aglomerativo # bottom-up

Cada cliente empieza solo; se une el par más parecido hasta quedar un solo grupo.

distancia_euclidiana

$d = \sqrt{\sum (x_i - y_i)^2}$

Línea recta entre dos clientes en el espacio de 9 variables.

ward # criterio de enlace

Une los grupos cuya fusión aumenta menos la varianza interna: grupos compactos.

● ● ● leer_dendrograma.md

eje X clientes (las hojas)

eje Y altura de fusión: más alto = grupos más distintos

corte una línea horizontal cruza tantas ramas como clústeres quieras

regla busca un salto grande entre una fusión y la siguiente

PCA: componentes y varianza

● ● ● conceptos_pca.py

componentes # PC1, PC2, ...

Combinaciones lineales de las variables, no correlacionadas y ordenadas por varianza.

varianza_explicada # % por componente

Cuánta información conserva cada eje. Con 2 ejes no se conserva toda.

cargas # loadings

Peso de cada variable en un componente: sirven para interpretar el eje.

● ● ● tres_ideas.md

idea 1 el clustering usa las 9 variables; el PCA solo sirve para dibujar

idea 2 en 2D los grupos pueden verse encimados aunque en 9D estén separados

idea 3 el signo de un eje es arbitrario; interpreta qué variables se agrupan

Cargar, auditar y estandarizar

● ● ● celdas_1_a_3.py

```
df = pd.read_excel("Amazon.xlsx").set_index("Cliente")    # 100 x 9
X = StandardScaler().fit_transform(df)    #  $z = (x - media) / desv\_est$ 
```

100 x 9

clientes x variables

Cómo leerlo

Sin nulos ni repetidos. Las desviaciones van de ~9 a ~188: sin escalar, Durabilidad domina la distancia.

Error común

Agrupar sin escalar: el ARI contra el resultado correcto es solo 0.14.


ARI 0.14

sin escalar vs. escalado

Construir y leer el árbol

● ● ● celdas_4_y_5.py

```
Z = linkage(X, method="ward", metric="euclidean")
umbral = (Z[-k,2] + Z[-(k-1),2]) / 2 # punto medio del salto
dendrogram(Z, labels=df.index, color_threshold=umbral)
```



Cómo leerlo

Cada U es una fusión y su altura es la distancia de Ward. La línea de corte (9.56) cruza 4 ramas.



Error común

Cortar en un número redondo: el 10 original quedaba pegado a una fusión (10.15).

¿Cuántos clústeres?

● ● ● celdas_6_y_7.py

```
saltos = [Z[-(k-1),2] - Z[-k,2] for k in ks]
silueta = silhouette_score(X, fcluster(Z, k, criterion="maxclust"))
```



Cómo leerlo

El mayor salto está en $k = 3$ y la silueta ronda 0.11 para todo k (razonable desde 0.25). Elegimos $k = 4$.


Error común

Llamar "óptimo matemático" a $k = 4$: es una decisión justificada.

Etiquetar clientes e interpretar

● ● ● celdas_8_a_10.py

```
modelo = AgglomerativeClustering(n_clusters=4, linkage="ward")
etiquetas = modelo.fit_predict(X)
perfil_z = df_escalado.groupby(etiquetas).mean() # heatmap
```



Cómo leerlo

Tamaños 21, 24, 36 y 19. Cian = sobre el promedio. 0 educativos, 1 paquetes grandes, 2 baja valoración, 3 calidad y durabilidad.


Error común

Fiarse del número de clúster: es arbitrario. Interpreta el perfil.

Varianza explicada

● ● ● celda_11.py

```
pca_completo = PCA().fit(X)
var_exp = pca_completo.explained_variance_ratio_
var_exp.cumsum() # 2 componentes = 36.1 %
```



Cómo leerlo

PC1 + PC2 suman 36.1 % y hacen falta 7 componentes para llegar al 80 %: la información está repartida.


Error común

Decir que 2 ejes no pierden información: se queda fuera el 63.9 %.

Dibujar en 2D e interpretar ejes

● ● ● celdas_12_y_13.py

```
pca = PCA(n_components=2); comp = pca.fit_transform(X) # solo para dibujar
cargas = pd.DataFrame(pca.components_.T, index=df.columns)
```



Cómo leerlo

PC1: Estrellas, Velocidad y V. educativo. PC2: Paquete, Precio, Estrellas y Durabilidad (negativa).

Error común

Juzgar los clústeres por el 2D: el clustering usa las 9 variables.

Clientes afines por distancia

● ● ● celda_14.py

```
comp = df_escalado[cluster == c].drop(index=cliente)
dist = np.sqrt(((comp - df_escalado.loc[cliente])**2).sum(axis=1))
afines = dist.sort_values().head(3)
```

0.32

Stephania · razonable

0.12

Lydia · frontera

0.08

Salome · frontera

Cómo leerlo

La silueta individual mide la solidez de la asignación: Stephania es razonable; Lydia y Salome están en la frontera.

Error común

Prometer productos: la base no tiene compras. Falta cruzar con el historial.

Clase MotorRecomendacionAmazon

● ● ● clase_pro.py

```
motor = MotorRecomendacionAmazon("Amazon.xlsx", n_clusters=4).entrenar_motor()  
motor.recomendar("Salome")  
motor.asignar_nuevo_cliente({...9 variables...})
```

sin predict

AgglomerativeClustering

centroide

segmento más cercano

Cómo leerlo

Encapsula ingesta, escala, clustering y recomendación. Los errores se lanzan con raise y las etiquetas se guardan aparte.

Error común

Asumir que hay predict: no lo hay; el cliente nuevo va al centroide más cercano.

Glosario

Aglomerativo

cada cliente empieza solo y se fusionan los más parecidos

Distancia euclidiana

línea recta entre dos puntos

Ward

fusión con menor aumento de varianza interna

Dendrograma

árbol de fusiones; la altura es la distancia

Estandarización

media 0 y desviación 1 por variable

Silueta

de -1 a 1: qué tan bien encaja un punto en su clúster

ARI

1 = particiones idénticas; 0 = azar

Componente principal

combinación lineal, no correlacionada, ordenada por varianza

Varianza explicada

porcentaje de información de cada componente

Cargas

peso de cada variable en un componente

Repaso y ejercicios

● ● ● repaso.py

?> ¿k = 4 es el óptimo? No: el mayor salto está en k = 3 y la silueta es plana. Es una decisión.

```
?> ¿Cuánta información muestra el 2D? 36.1 % de la varianza: una vista parcial.
```

```
>> ¿Qué significa una silueta de 0.08? El cliente está en la frontera entre dos grupos; su recomendación es menos fiable.
```

?> ¿Cómo se asigna un cliente nuevo? Se escala con el scaler ajustado y se toma el centroide más cercano.

● ● ● ejercicios.md

1. Prueba $k = 3$ y $k = 5$ y compáralos con ARI.
2. Cambia linkage a average o complete y compara la silueta.
3. Agrupa sobre PC1 y PC2 y compara con las 9 variables.